

L'erreur systématique d'un modèle "inadapté"

J.E Campagne

10 février 2026

Résumé

Quand la famille de modèles que l'on utilise pour ajuster des données (Poisson) ne contient pas le modèle théorique sous-jacent, la valeur minimum de la déviance de Poisson a une très faible p-value. Dans ce cas, on est en présence d'une dispersion accrue due à cet effet de biais de modèle. On peut caractériser cet effet par un modèle composite invoqué après la régression et intégrant une erreur systématique. Un exercice numérique illustre le propos [sur Github](#).

1 Introduction

Imaginons que l'on observe N données qui suivent un modèle théorique quadratique de type

$$\mu_i = ax_i^2 + bx_i + c \geq 0 \quad (1)$$

avec $\mathbf{x} = \{x_i\}_{i=1,\dots,N}$ sont fixés une fois pour toute et (a, b, c) trois coefficients également donnés *a priori* mais sont les inconnus du problème d'ajustement de modèles. Chaque observation y_i (indépendante des autres observations) à proprement parlée est la réalisation d'une distribution de Poisson (voire de Gauss) telle que

$$y_i \sim \text{Poisson}(\mu_i) \quad (2)$$

Un exemple est donné sur la Figure 1. L'ajustement par régression¹ d'un modèle quadratique (noté "bon" par la suite) permet d'avoir une estimation $\hat{\boldsymbol{\mu}} = \{\hat{\mu}_i\}_i$ approchée de $\boldsymbol{\mu} = \{\mu_i\}_i$. On obtient ainsi la courbe approximative du modèle sous-jacent des données : la courbe bleue à comparer à la courbe orange théorique. Cette régression assure la minimisation de la fonction connue sous le nom de *Poisson deviance*²

$$C(\boldsymbol{\mu}_\theta) = 2 \sum_{i=1}^N \left(y_i \log \left(\frac{y_i}{\mu_{\theta,i}} \right) - (y_i - \mu_{\theta,i}) \right) = 2 [\mathcal{L}(\mathbf{y}) - \mathcal{L}(\boldsymbol{\mu}_\theta)] \quad (3)$$

qui est la différence entre $\mathcal{L}(\mathbf{y})$, le log-likelihood maximal³ ne dépendant que des données, et $\mathcal{L}(\boldsymbol{\mu}_\theta)$ celui du modèle ajusté avec⁴ $\mu_{i,\theta} = f(x_i; \theta)$ où θ est le jeu de paramètres du modèle à trouver par la régression (ex. pour un modèle quadratique $\theta = (a, b, c)$). En l'occurrence, une fois la régression effectuée $\hat{\boldsymbol{\mu}} = \boldsymbol{\mu}_{\hat{\theta}}$ et $C(\hat{\boldsymbol{\mu}})$ prend la valeur minimum de $C_{min} = 85.25$ dans l'exemple numérique de la Figure 1.

Maintenant, la forme du modèle sous-jacent n'est pas forcément une information connue *a priori*. Un exemple est donné sur la Figure 2 où l'on a utilisé un modèle linéaire, noté "inadapté" par la suite. Il est clair que ne pas utiliser le "bon" modèle impacte la qualité de l'ajustement à travers les résidus ainsi que la valeur de C_{min} qui augmente notablement pour être égale à 138.25 dans l'exemple.

Bien entendu à la lumière de la forme des résidus de l'exemple, on peut tenter d'adapter le modèle à ajuster. Cependant, il n'est pas toujours si "évident" de déterminer la manière de modifier le modèle. Une

1. Par exemple en utilisant `linear_model.LinearRegression` de `scikit-learn` car les y_i sont de valeurs assez grandes, dans le cas contraire, il faut utiliser une régression poissonnienne avec `linear_model.PoissonRegressor`.

2. Notons que $z = (y - \mu)/\mu$, en faisant un développement à l'ordre 2 en $z \rightarrow 0$ et de plus $\mu \gg 1$ alors $C(\boldsymbol{\mu}) \approx \sum_i \frac{(y_i - \mu_i)^2}{\mu_i}$ qui est la statistique de Pearson.

3. où $\hat{\mu}_i = y_i$ pour tout i .

4. En principe, on prend pour $f(x; \theta)$ une expression exponentielle pour garantir la positivité. Dans notre exemple, la valeur des paramètres (a, b, c) du modèle théorique choisi permettent accommoder des formes polynomiales directement car le terme constant est suffisamment grand.




FIGURE 1 – Exemple d'un jeu de $N = 100$ données (points bleus) issus d'un modèle théorique (courbe orange) Equation 1 avec $(a, b, c) = (0.01, 0.1, 100)$ et d'une statistique de Poisson (Equation 2). Un fit d'un modèle quadratique donne la courbe bleue ainsi que les résidus (panel du bas, et leur distribution panel de droite en bas).

autre attitude courante est d'attribuer aux données une part de systématique qui vient s'ajouter à la part venant de la statistique de Poisson. Cela se fait en argumentant que C_{min} devrait suivre asymptotiquement⁵ la loi du $\chi^2(n_{dof})$, où n_{dof} représente le nombre de degrés de liberté qui en l'occurrence pour l'exemple utilisé est égal à $N - m$, avec m le nombre de paramètres du modèle (la taille du vecteur θ). Nous y reviendrons. *Une autre solution qui est le sujet de cette note est de prendre le parti que c'est bien le modèle qui est la source de l'erreur systématique.* Par la suite, la valeur de $C(\hat{\mu})$ dans le cas du modèle inadaptée est notée $C_{min,syst}$. La section suivante étudie les statistiques de C_{min} et $C_{min,syst}$.

2 Statistiques d'ensemble de C_{min} et $C_{min,syst}$

Reprenons l'exemple de l'introduction en répétant les ajustements des deux modèles, le "bon" (quadratique) et l'"inadapté" (linéaire) sur des jeux de données tous issus du même modèle théorique sous-jacent (Equation 1) et où seule compte la génération indépendantes des $\{y_i\}_i$ selon la loi de Poisson (Equation 2). La Figure 3 donne le résultat des distributions de C_{min} (gauche) et $C_{min,syst}$ (droite), ainsi que les valeurs de $C(\hat{\mu})$ (Equation 3) pour les deux modèles après ajustement des paramètres θ .

Comme attendu, on constate que les C_{min} se distribuent selon la loi du $\chi^2(n_{dof})$ avec $n_{dof} = N - m = 100 - 3 = 97$ en raison des grandes valeurs de μ_i (cf. coefficient $c = 100$) comme en atteste le diagrammes quantile-quantile⁶. Comme, le nombre d'échantillons N est grand, la loi du χ^2 converge vers une loi Gaussienne comme indiqué. Maintenant, concernant le modèle inadapté à $m = 2$ paramètres, on constate également que la distribution des $C_{min,syst}$ suivent une loi Gaussienne par le même jeu de convergence en loi. Notons que la valeur moyenne de 148.71 a une p-value de $6 \cdot 10^{-4}$ d'être issue de la distribution $\chi^2(97)$, elle est clairement trop grande.

Peut-on modéliser un tel comportement de la statistique de $C_{min,syst}$? C'est le domaine connu dans la

5. C'est-à-dire à N fixé $\mu_i \rightarrow +\infty \forall i$. Il en est de même de la valeur de la forme approximative de la note 2 dans laquelle μ_i est remplacée par $\hat{\mu}_i$.

6. Usage de la fonction `statsmodels.api.qqplot`.




FIGURE 2 – Même jeu de données que la Figure 1 mais ajusté par un modèle linéaire à 2 paramètres.

littérature sous le vocable de *overdispersion*, où l'on recherche une cause dans les données d'un élargissement de la *variance* sans toucher à la moyenne (les biais de mesures des y_i peuvent être absorbés par des paramètres du modèle ajusté). On peut modéliser ces "extra" variances par l'intermédiaire d'un *forward model* tel que par exemple

$$y_i \sim \text{Poisson}(\mu_i), \quad \mu_i \sim \text{Gamma}(\alpha_i, r_i) \quad \text{ou} \quad \mu_i \sim \text{LogNormal}(\alpha_i, r_i) \quad (4)$$

C'est-à-dire que l'on se donne *a priori* une loi sous-jacente, et le résultat est une composition de variables aléatoires (c.f *compounding representation*) qui tend à augmenter la variance des y_i (*overdispersed*). Cependant, se fixer ce cadre de composition est contraignant, et la question se pose alors de ce que l'on peut tirer d'un modèle "agnostique". Par la suite, je vais largement m'inspirer de l'article de [Bonamente et al. \(2025\)](#).

3 Modèle agnostique de l'élargissement de la variance des données : statistique de $C_{min,syst}$

Une fois que l'on a ajusté les données $\{y_i\}_i$ à l'aide d'une régression et obtenu les valeurs $\{f(x_i, \hat{\theta}) = \hat{\mu}_i\}_i$ qui minimise la *Poisson deviance* (Equation 3), on va supposer que ces valeurs sont en fait les moyennes de variables aléatoires (v.a) $\{M_i\}_i$ indépendantes entre elles et indépendantes des données, telles que

$$y_i \sim \text{Poisson}(M_i); \quad E(M_i) = \hat{\mu}_i, \quad \text{Var}(M_i) := \sigma_{int,i}^2 \quad (5)$$

En fait, les v.a M_i décrivent la *variabilité des résultats du modèle ajusté aux données qui sont fixées*. On ne conserve que les 2 premiers moments des distributions des M_i , où $\sigma_{int,i}^2$ introduit la variance systématique (*intrinsic*) du modèle. Notons que les espérances $E(y_i) = \mu_i$ sous l'hypothèse où le modèle est "bon" sont inchangées⁷, seules sont modifiées $\text{Var}(y_i) > \mu_i$, ce qui est l'effet recherché.

Dans ces conditions, la valeur $C_{min,syst}$ devient une v.a également que l'on note Z et telle que (Equa-

7. Si $N \gg 1$, les paramètres $\hat{\theta}$ convergent vers les valeurs "vraies" si on a choisi le "bon" modèle (estimateur non biaisé), et il en va de même pour les $\hat{\mu}_i = \mu_i(\hat{\theta})$ convergeant vers les μ_i .




FIGURE 3 – **Haut à Gauche** : Distribution des C_{min} issues de 10,000 simulations de données du même modèle théorique en faisant jouer la seule statistique de Poisson, et de leur ajustement par le "bon" type de modèle quadratique. On superpose la distribution du χ^2 à $n_{dof} = N - m = 97$ degrés de liberté. Comme $n_{dof} \gg 1$ cette loi du χ^2 est proche d'une loi Gaussienne où sont fixées la moyenne et le sigma tels que $\chi^2(n_{dof}) \underset{N \rightarrow \infty}{\sim} \mathcal{N}(n_{dof}, \sqrt{2n_{dof}})$. **Haut à Droite** : Pour les mêmes jeux de données, l'ajustement de modèles linéaires "inadaptés" donnent une distribution des $C_{min,syst}$ sur laquelle on a ajusté une loi gaussienne. **Bas** ; Diagrammes quantile-quantile des distributions des C_{min} versus la loi du $\chi^2(N - m = 100 - 3 = 97)$, et celles des $C_{min,syst}$ versus une loi Gaussienne.




FIGURE 4 – **Gauche** : Distribution des valeurs de $Y = C_{min,syst} - C_{min} = Z - X$ (voir Figure 3) et ajustement par une loi Gaussienne. **Droite** : Diagramme quantile-quantile correspondant.

tion 3) :

$$Z := C_{min,syst} = C(\mathbf{M}) = 2 \sum_{i=1}^N \left(y_i \log \left(\frac{y_i}{M_i} \right) - (y_i - M_i) \right) \quad (6)$$

Si l'on appelle $C_{min} = C(\hat{\mu}) =: X$ qui suit la distribution du $\chi^2(n_{dof})$ du "bon" modèle, alors la différence $Z - X =: Y$ est une v.a égale à l'expression

$$Y = 2 \sum_{i=1}^N \left(y_i \log \left(\frac{\hat{\mu}_i}{M_i} \right) - (\hat{\mu}_i - M_i) \right) \quad (7)$$

Notons que si les M_i suivent une distribution de Dirac, autrement dit le modèle ajusté n'a pas d'effet systématique, il est clair que Y s'annule. Cette variable Y signe bien la présence d'erreur systématique. Si l'on suppose que $\sigma_{int,i}^2 < \infty$ ce qui est raisonnable, et que N est suffisamment grand, alors la distribution de Y tend vers une distribution Gaussienne que l'on peut exprimer comme suit

$$Y \sim \mathcal{N}(\mu_c, \sigma_c^2) \quad (8)$$

Par la suite, la distribution des échantillons – obtenues après les multiples expériences – est ajustée⁸ par la Gaussienne $\mathcal{N}(\hat{\mu}_c, \hat{\sigma}_c^2)$. La Figure 4 donne le résultat en exploitant les simulations numériques.

Que peut-on dire de la distribution de $Z = X + Y$? Moyennant d'être dans un régime de grandes valeurs des μ_i , où $X \sim \chi^2(n_{dof})$, alors X est indépendant des $\hat{\mu}_i$ donc des M_i , ce qui implique l'indépendance entre X et Y . La loi limite de Z n'est autre que la convolution entre une loi de χ^2 et une gaussienne⁹ qui tend vers la convolution de deux gaussiennes quand $N \gg 1$, telle que

$$C_{min,syst} \sim \mathcal{N}(n_{dof} + \mu_c, 2n_{dof} + \sigma_c^2) \quad (9)$$

qui vient généraliser en présence de systématiques la relation

$$C_{min} \sim \mathcal{N}(n_{dof}, 2n_{dof}) \quad (10)$$

4 Expression de μ_c et σ_c

Pour obtenir une expression de μ_c et σ_c , on procède à un développement de l'expression de Y (Equation 7) à l'ordre 2 en $M_i - \hat{\mu}_i$:

$$Y \approx \sum_{i=1}^N \left(2 \left(1 - \frac{y_i}{\hat{\mu}_i} \right) (M_i - \hat{\mu}_i) + y_i \left(\frac{M_i - \hat{\mu}_i}{\hat{\mu}_i} \right)^2 \right) \quad (11)$$

8. Quand le nombre d'échantillons tend vers l'infini $\hat{\mu}_c \rightarrow \mu_c$ idem pour $\hat{\sigma}_c^2$.

9. Dans le notebook sur Github, il y a un petit extra qui donne des exemples d'une telle convolution et sa convergence vers une loi gaussienne.

On fixe alors les valeurs $\{\hat{\mu}_i\}_i$ et $\{\sigma_{int,i}\}_i$, en se rappelant que les valeurs des $\{y_i\}_i$ sont issues du processus de Poisson (Equation 2) ne dépendant que des $\{\mu_i\}_i$, et que les M_i sont indépendants des y_i . On peut alors écrire que

$$E[Y] = \mu_c \approx \sum_i \mu_i \frac{\sigma_{int,i}^2}{\hat{\mu}_i^2} \quad (12)$$

Posons le changement de variable

$$\sigma_{i,int} = f_i \times \hat{\mu}_i \quad (13)$$

qui permet de simplifier l'écriture

$$E[Y] = \mu_c \approx \sum_i \mu_i f_i^2 \quad (14)$$

Chaque f_i quantifie en quelque sorte le niveau de systématique par rapport à la moyenne de la distribution sous-jacente de y_i . Concernant la variance de Y , la démonstration est faite dans l'Appendice B.3 de [Bonamente et al. \(2025\)](#) pour obtenir l'approximation suivante :

$$\text{Var}(Y) = \sigma_c^2 \approx 4 \sum_i \mu_i f_i^2 + \sum_i (\text{kurt}(M_i)(\mu_i + \mu_i^2) - \mu_i^2) f_i^4 \quad (15)$$

où $\text{kurt}(M_i)$ est le coefficient de kurtosis de la distribution des $\{M_i\}_i$ qui vaut 3 dans le cas où $M_i \sim \mathcal{N}(\hat{\mu}_i, \sigma_{int,i}^2)$ que l'on suppose par la suite pour des applications numériques¹⁰.

5 Estimation du niveau de systématique

A priori, on peut être confronté à la situation où les valeurs de $\sigma_{i,int}^2$ ne sont pas connues. Comment alors avoir une idée du niveau d'erreur systématique ?

Tout d'abord, en utilisant le résultat de notre expérimentation présenté sur la Figure 4 et en supposant de plus que les $\{f_i\}_i$ prennent une valeur constante $\hat{f}$, alors

$$\hat{f} \approx \left(\frac{\hat{\mu}_c}{\sum_i \mu_i} \right)^{1/2} \approx 7\% \quad (16)$$

On est donc dans un régime de systématiques assez modéré, aux effets néanmoins non négligeables comme on l'a constaté sur la valeur de la moyenne des $C_{min,syst}$ (Figure 3).

Que faire maintenant si l'on ne dispose que d'un seul jeu de données $\{y_i\}_i$? Une approximation de $\hat{\mu}_c$ et $\hat{\sigma}_c$ peuvent être obtenues simplement en utilisant les Equations 14,15 et en faisant la substitution $\mu_i \rightarrow y_i$, expressions que l'on simplifie en supposant $f_i = \hat{f}$:

$$\hat{\mu}_c \approx f_i^2 = \hat{f} \times \sum_i y_i \quad (17)$$

$$\hat{\sigma}_c^2 \approx 4\hat{\mu}_c + \hat{f}^4 \times \sum_i (\text{kurt}(M_i)(y_i + y_i^2) - y_i^2) \quad (18)$$

Pour obtenir un intervalle de confiance de $\hat{f}$, on se rappelle que $X = C_{min}$ ("bon" modèle) suit une loi de $\chi^2(N - m = n_{dof})$ et $Y \sim \mathcal{N}(\hat{\mu}_c, \hat{\sigma}_c^2)$. On s'attend donc à ce que la valeur observée de la Poisson déviance une fois ajusté le modèle ("inadapté"), notée $\hat{C}_{min,syst}$, soit telle que

$$\hat{\mu}_c = \hat{C}_{min,syst} - n_{dof} \quad (19)$$

Donc, cela nous permet d'obtenir une estimation de $\hat{f}$ via Equation 17 et de $\hat{\sigma}_c^2$ en utilisant Equation 18. Ensuite, d'après la distribution de $C_{min,syst}$ (Equation 9) on peut raisonnablement s'attendre à

$$\sigma^2(\hat{C}_{min,syst}) = 2n_{dof} + \hat{\sigma}_c^2 \quad (20)$$

10. Si on considère une distribution Gamma ou Lognormal, la correction à la valeur 3 est d'ordre f^2 , facteur que l'on néglige.

et

$$\sigma^2(\hat{C}_{min,syst}) = \sigma^2(\hat{\mu}_c) = \sigma^2(\hat{f}^2) \times \left(\sum_i y_i \right)^2 \quad (21)$$

Ainsi, l'intervalle de confiance sur $\hat{f}^2$ peut s'écrire selon

$$\hat{f}^2 = \frac{\hat{C}_{min,syst} - n_{dof} \pm \sqrt{2n_{dof} + \hat{\sigma}_c^2}}{\sum_i y_i} \quad (22)$$

que l'on peut transformer pour obtenir un intervalle pour $\hat{f}$.

Par exemple, si on prend un lot $\{y_i\}_i$ dans notre expérimentation, on trouve

$$\hat{C}_{min,syst} = 138.51 \Rightarrow \hat{\mu}_c = 40.25 \Rightarrow \hat{f} = 0.061 \Rightarrow \hat{\sigma}_c^2 = 194.26 \Rightarrow \hat{f}^2 = 3.69 \cdot 10^{-3} \pm 1.59 \cdot 10^{-3}$$

Donc, une estimation de $\hat{f}$ avec ce jeu unique de données donne finalement

$$\hat{f} = (6.08 \pm 1.31) \cdot 10^{-2} \quad (23)$$

qui est bien compatible avec l'estimation Equation 16.

6 Conclusion

Dans le cas où l'on observe une trop grande valeur de la déviance de Poisson après la régression d'un modèle sur un jeu de données, et que la source est possiblement l'usage d'un modèle inadapté, on peut tenter de quantifier le niveau d'erreur systématique du modèle. La note a résumé une partie de l'article de [Bonamente et al. \(2025\)](#) et l'a illustré sur une simulation numérique. L'idée maîtresse est de garder la statistique de Poisson des données et de modéliser le paramètre des distributions par une variable aléatoire dont on fixe seulement (1) l'espérance par le résultat de la régression, et (2) la variance par l'erreur systématique. On dispose alors de la modélisation du minimum de la déviance de Poisson du modèle inadapté qui généralise l'expression obtenue en absence de systématique. Moyennant quelques manipulations, on peut obtenir un intervalle de confiance sur le niveau de systématique en utilisant les données elles-mêmes.

Références

M. Bonamente, Y. Chen, and D. Zimmerman, [The Astrophysical Journal](#) **980**, 139 (2025).